Graph Neural Networks : étude, implémentation et synergie avec les LLM

Cas d'étude : connectivité dans un réseau 5G

Réalisé par : Fatima-Ezzahra Ghanam · Houda Bouya

Encadrant : Hassan EL GHAZI

Année universitaire : 2026/2027

SOMMAIRE

Fil conducteur de la présentation

01 **Contexte et problématique**

Pourquoi un graphe pour la 5G ?

02 **Fondements des GNN**

Message passing, agrégations, GCN · GAT · GraphSAGE

03 **Implémentation 5G**

Modèle radio, graphe UE–gNB, GCN à 2 couches

04 **Résultats et analyse**

Courbes, accuracy, matrice de confusion, ablations

05 **CNN vs GNN**

Tableau comparatif, forces et limites

06 **Bonus et conclusion**

Synergie LLM + GNN, bilan, perspectives

CONTEXTE

Des données de plus en plus relationnelles

Au-delà des grilles et des séquences

Le deep learning excelle sur les pixels (images) et les séquences (texte, audio). Une grande partie des données réelles est relationnelle :

- Réseaux sociaux
- Molécules
- Graphes de connaissances
- Réseaux routiers
- Télécommunications

Les GNN apprennent directement sur ces structures.

Un réseau 5G : un graphe naturel

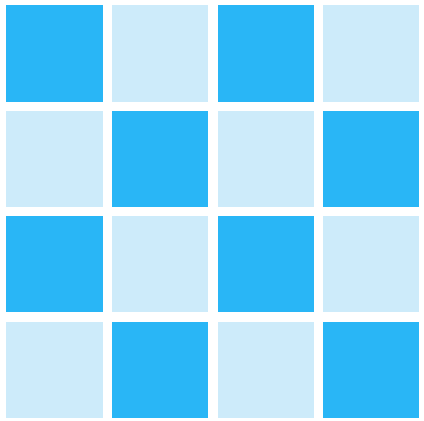
La qualité de service d'un UE dépend de :

- **Sa mesure radio propre**
  puissance reçue, SINR, distance
- **La charge de sa cellule**
  trafic servi / capacité du gNB
- **L'interférence des cellules voisines**
  information accessible via la topologie

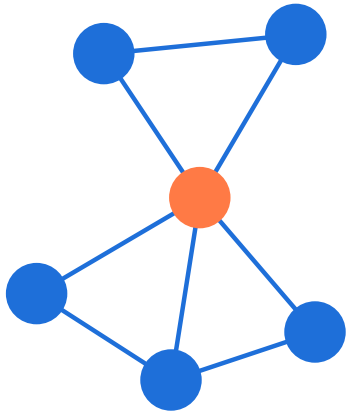
PROBLÉMATIQUE

Un modèle qui tient compte de la topologie du réseau peut-il mieux prédire la qualité de connectivité d'un utilisateur qu'une règle classique n'utilisant que ses mesures individuelles ?

Pourquoi CNN et RNN sont inadaptés aux graphes



Grille : voisinage fixe et ordonné



Graphe : degré variable, aucun ordre

Pas d'ordre canonique

Ni gauche/droite ni haut/bas : renuméroter les nœuds ne change pas le graphe mais change l'entrée d'un réseau classique.

Degré variable

Un nœud peut avoir 1 ou 10 000 voisins : un noyau de taille fixe n'a pas de sens.

Taille variable

Les graphes d'un jeu de données n'ont pas le même nombre de nœuds, contrairement à des images redimensionnées.

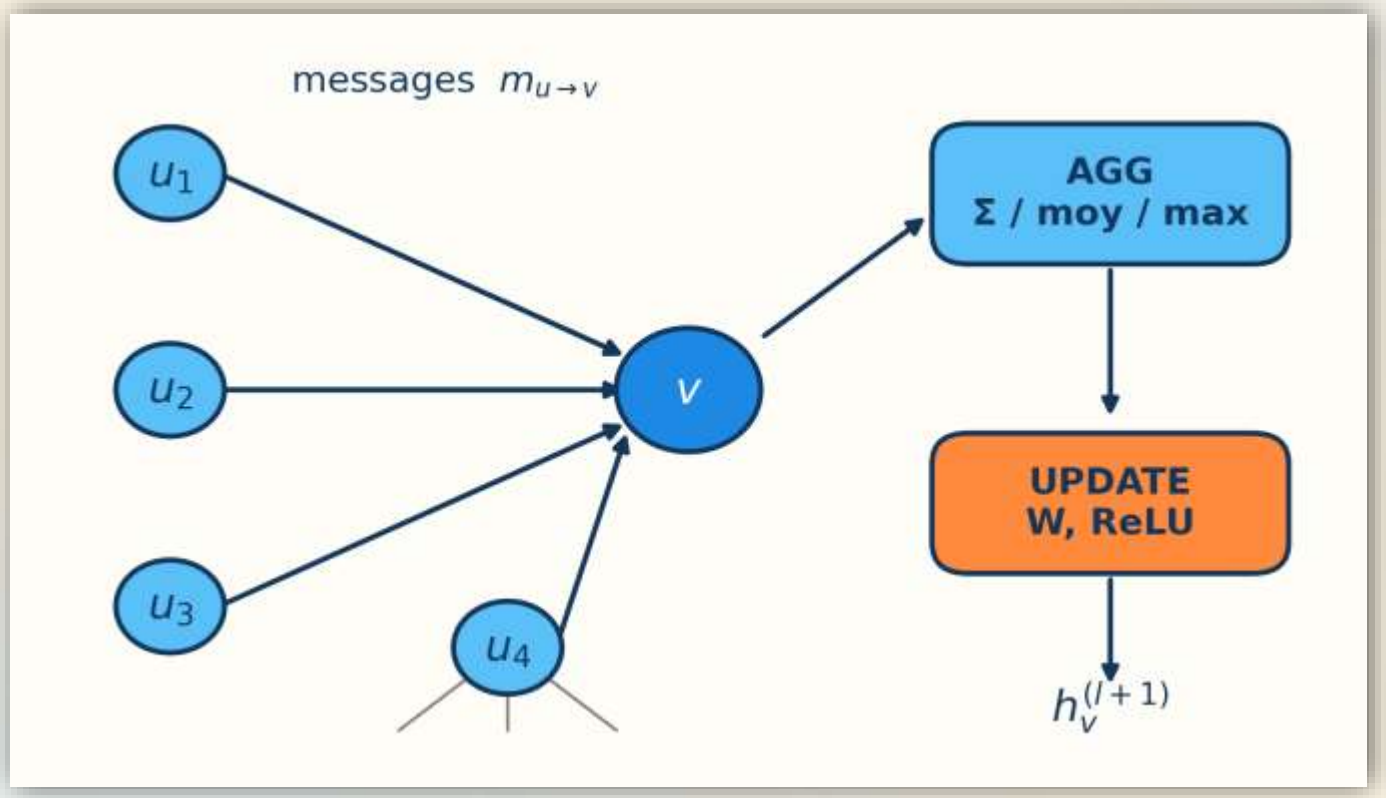
RNN et MLP

Linéariser un graphe impose un ordre arbitraire et détruit les relations locales ; un MLP sur A aplatie dépend de l'ordre et de N.

Réponse des GNN : opérateurs locaux, à poids partagés et équivariants aux permutations.

SCHÉMA 1

Le cœur du GNN : le message passing



MESSAGE
MSG(hu, hv, euv) pour chaque voisin u

AGRÉGATION
AGG : somme · moyenne · max

MISE À JOUR
UPDATE(W, σ) combine mv et hv

$h_v^{(l+1)}$ **: nouvelle représentation, champ récepteur à L sauts**

$$h_v^{(l+1)} = \sigma(W^{(l)} \cdot [h_v^{(l)} \,\|\, AGG(\{ MSG(h_u, h_v, e_uv) : u \in N(v) \})])$$

Trois fonctions d'agrégation

Σ Somme

$$m_v = \Sigma\, h_u$$

Avantage
Préserve la multiplicité du voisinage ; expressivité maximale des trois [8].

Limite
Amplitude liée au degré : risque d'instabilité sur les nœuds très connectés.

μ Moyenne

$$m_v = (1/|N(v)|)\, \Sigma\, h_u$$

Avantage
Normalise par le degré : stable, adaptée aux degrés hétérogènes.

Limite
Perd la cardinalité : deux multi-ensembles proportionnels sont indiscernables.

max Maximum

$$m_v = max\, h_u$$

Avantage
Capte les signaux saillants ; robuste aux valeurs moyennes bruitées.

Limite
Perd multiplicité et distribution ; peu sensible aux petites variations.

Condition de validité : AGG doit être invariante aux permutations (les voisins n'ont pas d'ordre).

Propriétés fondamentales des GNN

1	**Équivariance aux permutations**	Renumérotter les nœuds ne change pas le résultat. Pour un graphe entier, on ajoute une lecture globale (readout) invariante.	ATOUT
2	**Localité et partage de paramètres**	Le nombre de paramètres est indépendant de N : la même matrice W sert tous les nœuds.	ATOUT
3	**Expressivité bornée**	Les MPNN sont au plus aussi discriminants que le test de Weisfeiler–Leman [8].	LIMITE
4	**Sur-lissage (over-smoothing)**	Trop de couches rendent les représentations quasi identiques [11] : 2 à 3 couches suffisent généralement.	LIMITE
5	**Goulot d'étranglement (over-squashing)**	L'information de voisins lointains est compressée dans un vecteur de taille fixe [12].	LIMITE

Architectures majeures : GCN, GAT, GraphSAGE

GCN
Kipf & Welling [1]

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-½} \tilde{A} \tilde{D}^{-½} H^{(l)} W^{(l)} \right)$$

Moyenne pondérée symétriquement normalisée, avec boucles propres ($\tilde{A} = A + I$).

Forces : Simple, peu de paramètres, efficace.

Limites : Poids fixés par la topologie ; sensible au sur-lissage.

Classe PyG : `GCNConv`

GAT
Veličković et al. [2]

$$h^{(l+1)} = \sigma\left(\Sigma\, \alpha_{vu}\, W\, h_u \right)$$

Chaque voisin est pondéré par un coefficient d'attention appris ; plusieurs têtes.

Forces : S'adapte à l'importance de chaque voisin ; interprétable.

Limites : Coût plus élevé ; GATv2 corrige l'attention statique [13].

Classe PyG : `GATConv`

GraphSAGE
Hamilton et al. [3]

$$h^{(l+1)} = \sigma\left(W \cdot [\, h_v \,\|\, AGG\, h_u \,] \right)$$

Échantillonne un nombre fixe de voisins ; concatène le nœud et son voisinage.

Forces : Inductif : nœuds et graphes jamais vus ; passage à l'échelle.

Limites : Agrégateur uniforme : pas de poids appris par voisin.

Classe PyG : `SAGEConv`

Synthèse : comparer les trois architectures

	GCN [1]	GAT [2]	GraphSAGE [3]
Pondération des voisins	Fixe (degrés)	Apprise (attention)	Uniforme selon l'agrégateur
Régime	Transductif (en pratique aussi inductif)	Transductif / inductif	Inductif
Coût	Faible	Modéré à élevé	Contrôlé par l'échantillonnage
Classe PyG	`GCNConv`	`GATConv`	`SAGEConv`

Principe

Le GNN généralise la convolution aux domaines irréguliers par agrégation locale et invariante.

Différences

GCN, GAT et GraphSAGE se distinguent par la pondération des voisins, le régime et le coût.

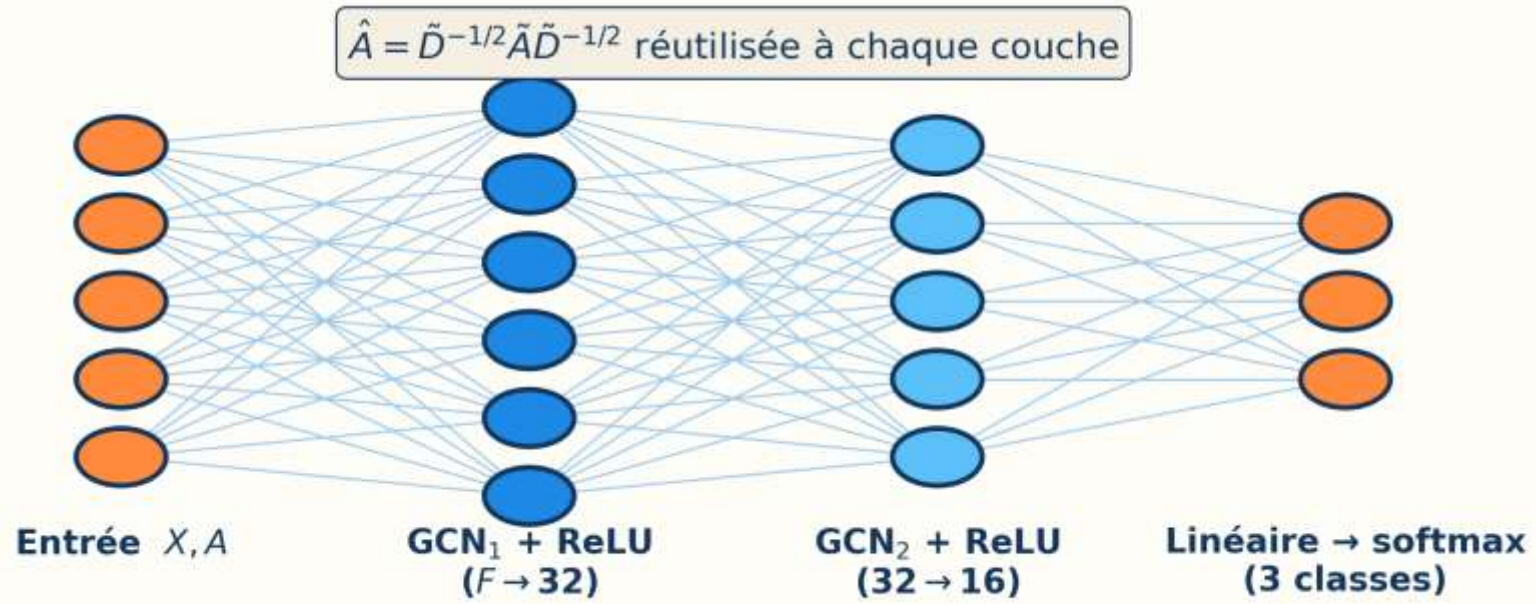
Choix du projet

GCN à 2 couches : simple, peu de paramètres, adapté à notre problème 5G.

Synthèse : GCN est simple et léger ; GAT apprend l'importance des voisins ; GraphSAGE passe à l'échelle.

SCHÉMA 2

Architecture du GCN à deux couches



Champ récepteur

2 couches = 2 sauts : un UE reçoit l'information de sa cellule puis, via les arêtes gNB–gNB, celle des cellules voisines.

Entraînement

Adam (lr 0,01), weight decay $5 \cdot 10^{-4}$, 200 époques, CrossEntropyLoss ; meilleur état retenu sur la validation.

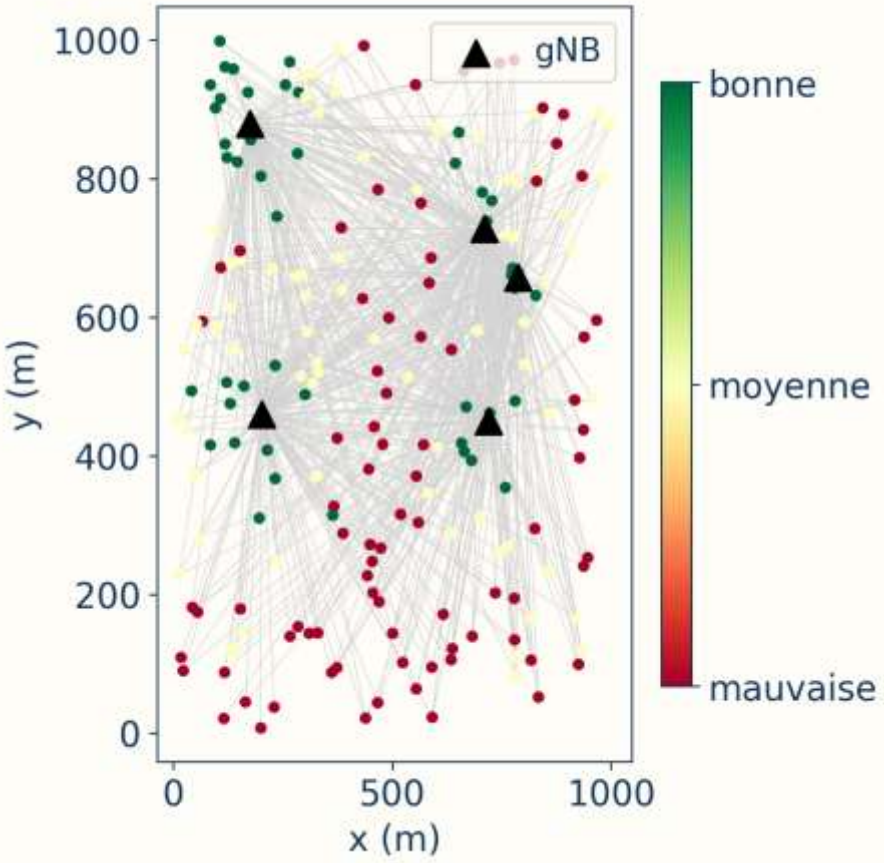
Sortie

Un vecteur de 3 logits par nœud UE : mauvaise, moyenne ou bonne connectivité.

Synthèse : GCN 32 → 16 → linéaire, 3 classes : mauvaise, moyenne, bonne.

CHAPITRE 2

Modélisation : le réseau 5G comme graphe



- 5 gNB, 200 UE, zone 1000 × 1000 m
- Arête UE-gNB si Pr > −100 dBm
- Classes : SINR < 5 dB · 5-15 dB · ≥ 15 dB
- Effectifs : 81 mauvaises · 73 moyennes · 46 bonnes

Synthèse : Les UE en rouge sont surtout éloignés de leur gNB (zone sud peu couverte, bords de cellule) : le SINR y est limité par le bruit et la faible puissance reçue, l'interférence aggravant le cas aux frontières.

Modèle radio simplifié et labels

Puissance reçue

$$P_r^{(ij)} = P_t - PL(d_{ij}) + X_\sigma$$

Affaiblissement

$$PL(d) = PL_0 + 10\, n \log_{10}(d / d_0)$$

SINR de l'UE i

$$SINR_i = p_{i,s(i)} / \left(\Sigma_{k \neq s(i)} \rho_k\, p_{ik} + N_0 \right)$$

ρk ∈ [0,05 ; 1] : charge du gNB k, un gNB plus chargé interfère davantage. Xσ ~ N(0, σ²) : ombrage log-normal.

< 5 dB	5 – 15 dB	≥ 15 dB
y = 0 · mauvaise	y = 1 · moyenne	y = 2 · bonne

43 dBm
Pt : puissance émise

43,3 dB
PL0 à d0 = 1 m

3,5
exposant n

4 dB
ombrage σ

−94 dBm
bruit N0

400 Mbps
capacité d'un gNB

−100 dBm
seuil de couverture Pmin

3,5 GHz
ordre de grandeur de PL0

Caractéristiques des nœuds et absence de fuite

Idx	Variable	Description / normalisation
0	`type`	0 = UE, 1 = gNB
1–2	`x, y`	Position, divisée par 1000 m
3	`trafic / degré`	UE : trafic /20 Mbps · gNB : fraction d'UE
4	`Pr`	UE : puissance reçue du gNB servant, (Pr+110)/60
5	`distance`	UE : distance au gNB servant, /500 m
6	`charge`	gNB : charge ρk ; 0 pour les UE

Constantes de normalisation fixes (physiques) : aucune statistique du jeu de test n'est utilisée.

Prévention de la fuite de données

- Le SINR sert uniquement à définir les labels.
- Il dépend de l'interférence des voisins, donc de leur charge : accessible à l'UE seulement via la topologie.
- Split 70/15/15 sur les UE ; le test n'est jamais utilisé pour choisir le modèle.

Pipeline reproductible de bout en bout

1 Génération

5 gNB, 200 UE, trafic gamma, ombrage log-normal

→

2 Graphe PyG

UE–gNB si Pr > −100 dBm ; gNB–gNB complet

→

3 Modèles

GCN 32→16→3, MLP sans voisinage, règle à seuils

→

4 Entraînement

Adam, lr 0,01, 200 époques, meilleur état sur validation

→

5 Évaluation

Test (15 %) : accuracy, F1 macro, matrice de confusion

Trois modèles comparés

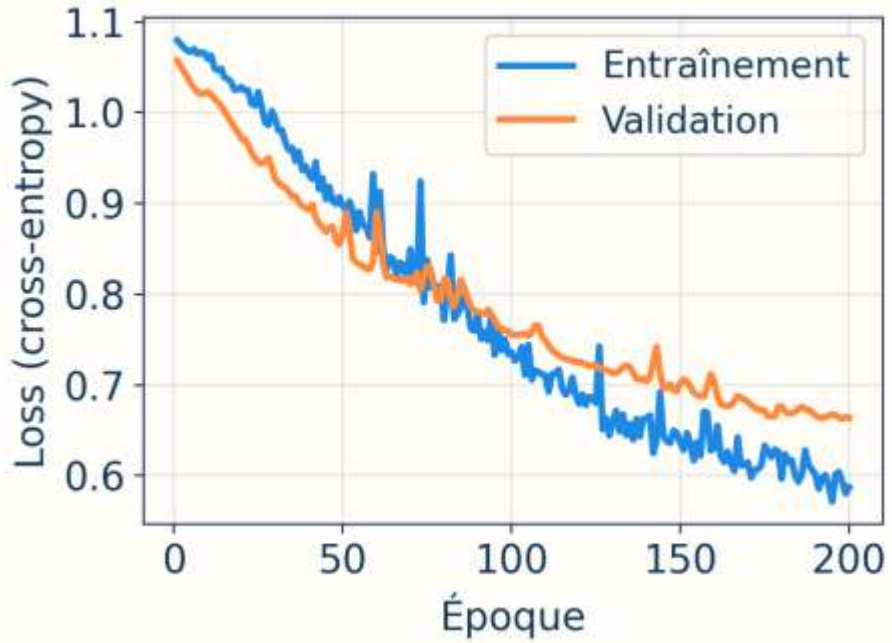
- **Règle à seuils :** seuils t1, t2 sur Pr ajustés sur le train
- **MLP :** même profondeur, sans topologie (ablation)
- **GCN :** agrégation du voisinage sur 2 sauts

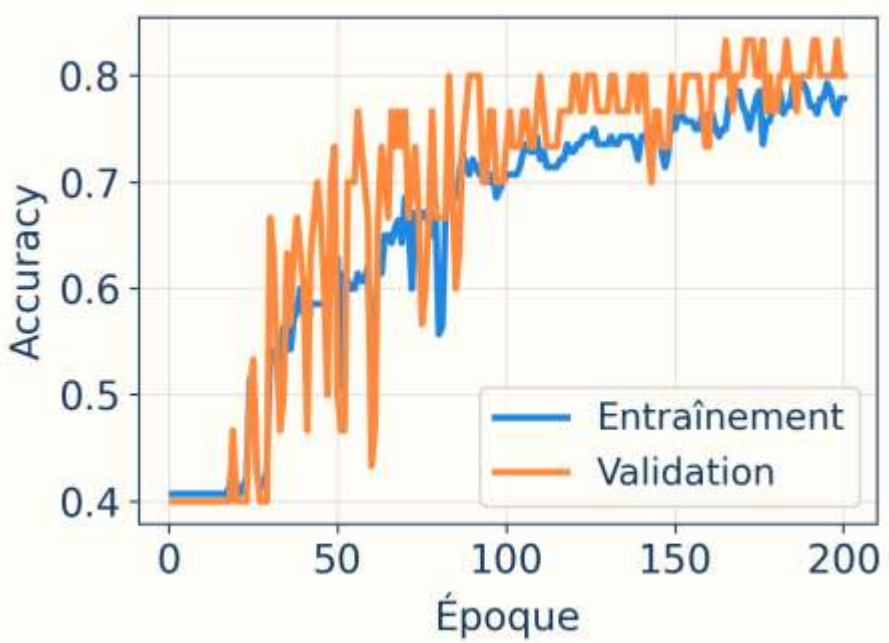
Garde-fous méthodologiques

- Graine fixe (42), dropout 0,3, régularisation L2
- Sélection du modèle sur la validation uniquement
- Moyenne ± écart-type sur 10 scénarios indépendants

RÉSULTATS

Courbes d'apprentissage du GCN





1,08 → ≈ 0,58
loss d'entraînement

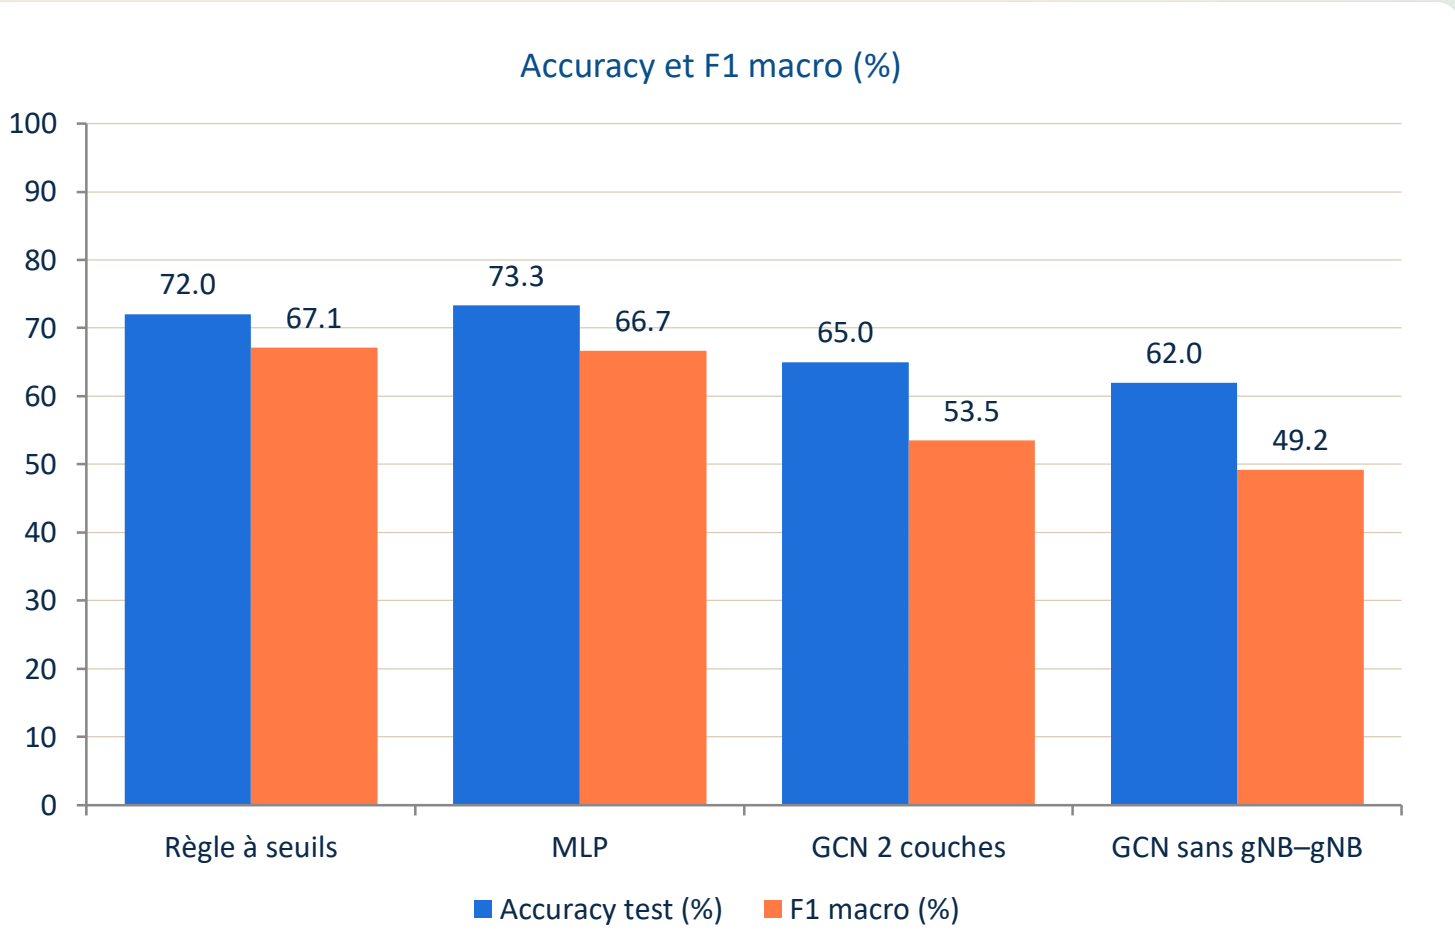
≈ 0,66
loss de validation (fin)

≈ 78 %
accuracy d'entraînement

≈ 80 %
accuracy de validation

Synthèse : la loss décroît encore à 200 époques : **sous-apprentissage**, pas de surapprentissage.

Performances sur le jeu de test (10 scénarios)



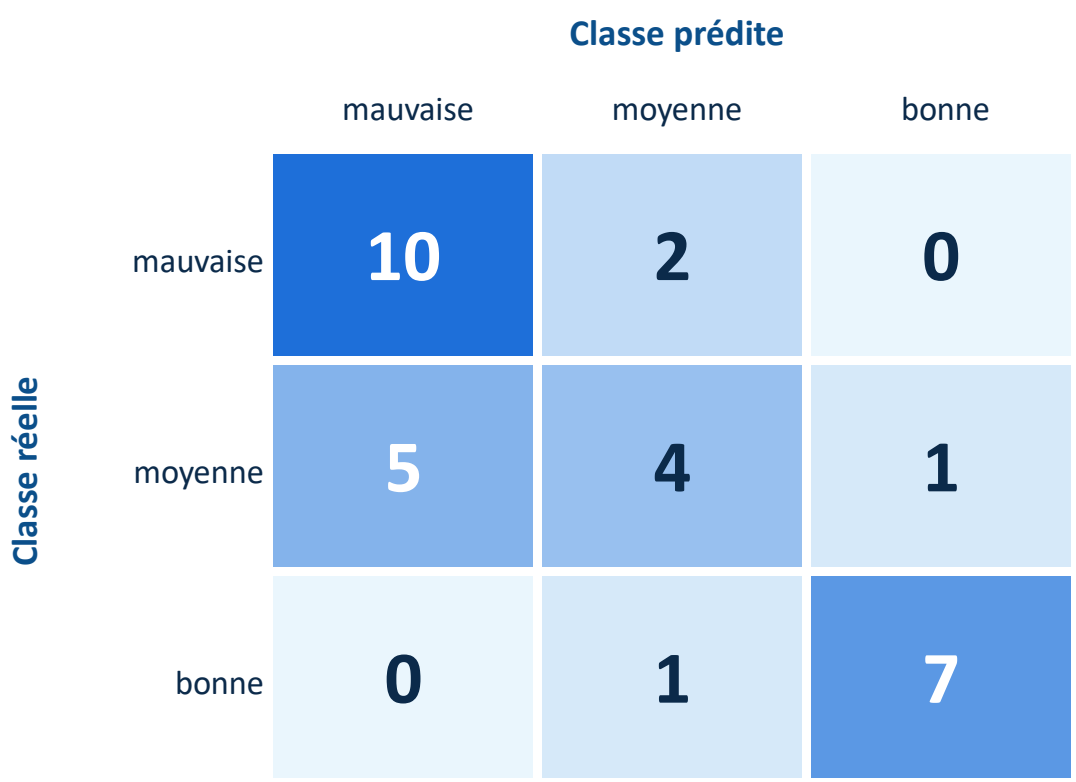
Méthode	Accuracy	Topologie
Règle sur Pr	72,0 ± 5,6	Non
MLP	73,3 ± 10,0	Non
GCN	65,0 ± 12,8	Oui
GCN sans gNB–gNB	62,0 ± 13,2	Partielle

À retenir

- La règle et le MLP dépassent le GCN en moyenne
- Écarts-types élevés : aucune conclusion tranchée

RÉSULTATS

Matrice de confusion du GCN (test, graine 42)



Diagonale : 10 + 4 + 7 = 21 bien classés sur 30

Classe	Rappel	Précision	Support
Mauvaise	83 %	67 %	12
Moyenne	40 %	57 %	10
Bonne	88 %	88 %	8

Analyse

- La classe « moyenne », entre deux seuils, est la plus fragile : une petite erreur d'estimation du SINR suffit à changer de classe.
- La classe « mauvaise » (rappel 83 %) est la plus critique pour l'opérateur.

ANALYSE CRITIQUE

Résultat honnête : le GCN ne bat pas les références

Accuracy test, scénario de référence (graine 42)

70 %
GCN

76,7 %
MLP

70 %
Règle à seuils

Pourquoi ?

La puissance reçue du gNB servant explique déjà l'essentiel du SINR ; le voisinage n'apporte qu'une information de second ordre.

Variance élevée

Environ 30 UE de test par scénario : d'où la moyenne sur 10 scénarios et des écarts-types qui interdisent toute conclusion tranchée.

Diagnostic

Loss encore décroissante à 200 époques : sous-apprentissage. Pistes : plus d'époques, lr plus élevé, plus d'UE, normalisation des degrés.

ANALYSE CRITIQUE

Impact de la topologie et surapprentissage

Deux ablations pour isoler la structure

- **GCN vs MLP :** mêmes caractéristiques, même profondeur ; seule l'agrégation de voisinage change.
- **Perturbation de la topologie :** suppression ou remplacement aléatoire des arêtes gNB–gNB.

65,0 % ⟶ **62,0 %**

sans arêtes gNB–gNB : dégradation dans le sens attendu, mais dans la marge d'incertitude.

Surapprentissage : remèdes

Jeu d'entraînement petit (≈ 140 UE) pour quelques milliers de paramètres.

- Dropout (0,3)
- Régularisation L2 (weight decay)
- Sélection du meilleur état sur la validation
- Arrêt précoce
- Plus de scénarios générés

ANALYSE CRITIQUE

Limites de l'étude et pistes d'amélioration

1 Données synthétiques

Modèle radio simplifié : validité externe limitée (extension vers ns-3 / 5G-LENA).

2 Classification ≠ débit

Une bonne accuracy n'implique pas une amélioration du débit ou de la latence.

3 Cible circulaire

Pas de fuite directe du label ; dépendance indirecte via les charges ρ_k

4 Comparaison de référence

Le « meilleur SINR » du guide est approché par la règle à seuils sur Pr.

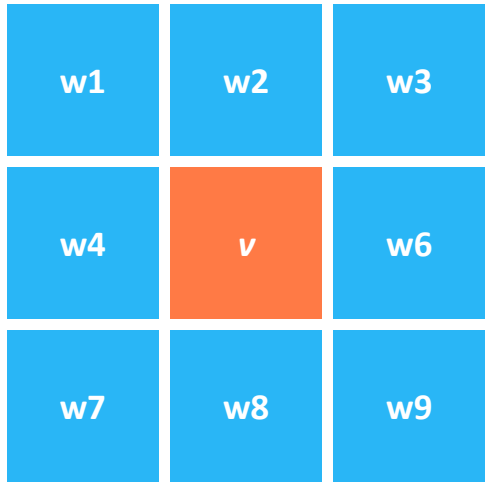
Pistes d'amélioration

- Plus d'époques et taux d'apprentissage plus élevé
- Plus d'UE par scénario
- Normalisation des degrés
- Pondération des classes dans la loss (rappel de « mauvaise »)
- Prédiction du meilleur gNB par link prediction

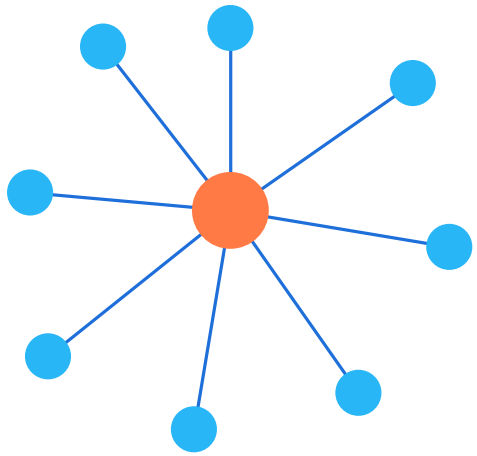
Comparatif structuré : CNN vs GNN

Critère	CNN	GNN
Données d'entrée	Grilles régulières (images, vidéos, signaux 1D)	Graphes irréguliers : nœuds et arêtes variables, attributs
Voisinage	Fixe, euclidien : noyau k × k ordonné	Variable, non euclidien : degré quelconque, voisins sans ordre
Invariance aux permutations	Non invariant : permuter les pixels change la sortie	Équivariant par nœud, invariant après readout
Partage de paramètres	Par translation (noyau glissant)	Entre tous les nœuds (même W)
Opérateur de base	Convolution discrète	Message passing / convolution sur graphe
Domaines typiques	Vision, imagerie médicale, reconnaissance de formes	Réseaux sociaux, molécules, graphes de connaissances, télécoms

Le CNN, cas particulier de GNN



noyau 3 × 3 : un poids par position relative



8 voisins, sans poids positionnels

Le GNN renonce à l'ordre pour obtenir l'invariance, au prix de la position relative (sauf attribut d'arête).

Quel paradigme choisir ?

Grille régulière disponible ?
Le CNN est le choix par défaut.

Relations entre entités au cœur du problème ?
Le GNN est justifié.

Projet 5G
Positions et mesures d'UE irrégulières, voisinage radio sans structure de grille : le GNN est pertinent.

Forces et limites : CNN et GNN

CNN · forces

- Biais adaptés aux images (localité, translation)
- Opérations denses optimisées sur GPU
- Écosystème mature, modèles pré-entraînés

CNN · limites

- Inadapté aux structures irrégulières
- Champ récepteur limité en profondeur
- Non invariant aux rotations sans augmentation
- Pas de relations arbitraires entre éléments

GNN · forces

- Données relationnelles traitées naturellement
- Généralise à des graphes de tailles différentes
- Topologie prise en compte explicitement
- Applicable en inductif (GraphSAGE)

GNN · limites

- Sur-lissage et goulot d'étranglement [11, 12]
- Expressivité bornée par Weisfeiler–Leman [8]
- Calcul irrégulier, passage à l'échelle difficile
- Dépend de la qualité du graphe (choix des arêtes)
- Pas de standard d'architecture établi

BONUS

Pourquoi combiner LLM et GNN ?

LLM (Transformer [17])

Forces

- Compréhension et raisonnement textuels, génération

Limites

- Structure relationnelle complexe mal gérée : un graphe sérialisé est long, d'ordre arbitraire
- Hallucinations de faits non ancrés
- Fenêtre de contexte limitée

+

GNN

Forces

- Encodage efficace de la topologie

Limites

- Entrées numériques : texte des nœuds mal compris
- Peu de raisonnement global ni de généralisation en langage naturel
- Dépendance aux étiquettes, aucune connaissance pré-entraînée

Complémentarité : le LLM apporte le texte et le raisonnement, le GNN apporte la structure.

BONUS

Trois cas d'usage majeurs

1 GraphRAG

Un graphe de connaissances remplace ou complète l'index vectoriel : entités, relations, communautés, résumés hiérarchiques [19]. Un GNN peut scorer les sous-graphes pertinents (G-Retriever [23]).

Intérêt : Multi-sauts, traçabilité, moins d'hallucinations.

2 Alignement texte–graphe

Encodeur de graphe et encodeur de texte alignés dans un espace latent commun, par apprentissage contrastif ou projecteur appris vers le LLM.

Intérêt : Recherche de nœuds par requête, classification zéro-coup, QA sur graphes.

3 Embeddings enrichis

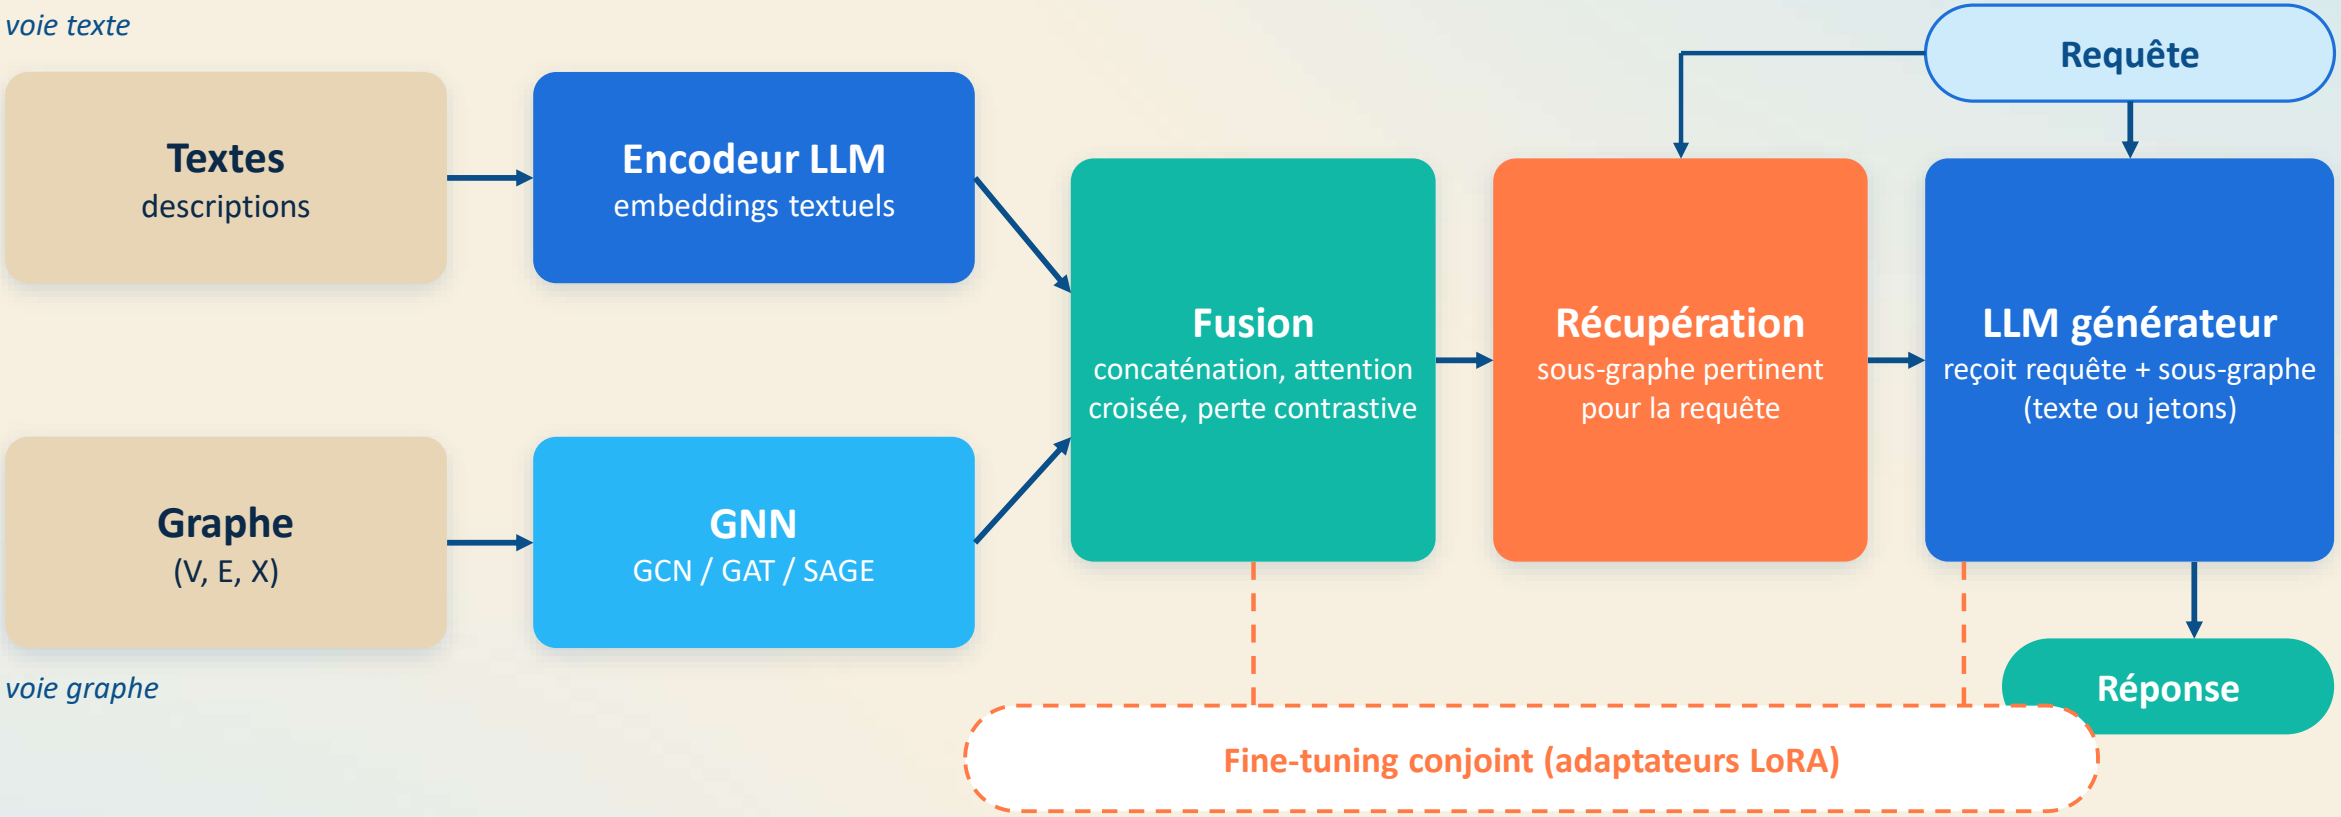
Un LLM génère explications, résumés ou pseudo-étiquettes ; un modèle de langage plus petit les convertit en caractéristiques denses pour le GNN [22].

Intérêt : Nœuds à attributs textuels : articles, produits, équipements réseau.

Dans notre contexte 5G : journaux d'incidents ou descriptions de cellules (« cellule rurale, forte pente, incidents de congestion répétés ») convertis en vecteurs et ajoutés aux caractéristiques radio.

SCHÉMA 3

Architecture type de la synergie LLM + GNN



Deux voies parallèles (texte, graphe) → fusion → sous-graphe pertinent → génération ancrée.

BONUS

Fusion d'embeddings textuels et structurels

```
class TextAugmentedGCN(torch.nn.Module):
    def __init__(self, d_num, d_txt, hidden=32, out_ch=3):
        super().__init__()
        self.txt_proj = torch.nn.Linear(d_txt, 16)
        self.conv1 = GCNConv(d_num + 16, hidden)
        self.conv2 = GCNConv(hidden, out_ch)

    def forward(self, x, text_emb, edge_index):
        z = torch.cat([x, torch.relu(self.txt_proj(text_emb))], dim=1)
        z = torch.relu(self.conv1(z, edge_index))
        return self.conv2(z, edge_index)
```

text_emb [N, d_txt] est précalculé (sentence-transformer ou LLM) ; la projection réduit sa dimension à 16.

Limites et défis

- Coût d'inférence des LLM
- Qualité d'extraction du graphe (entités, relations)
- Perte d'information à la textualisation
- Alignement des espaces de représentation
- Peu de bancs d'essai standardisés
- 5G : confidentialité, donc déploiements locaux

CONCLUSION

Bilan : ce que nous avons établi

1 Fondements

Message passing, agrégations, GCN, GAT, GraphSAGE : les GNN généralisent la convolution aux domaines irréguliers.

2 Cas d'étude 5G

Réseau UE–gNB modélisé en graphe, GCN à 2 couches sans fuite de données, comparé à deux références.

3 Comparatif CNN vs GNN

CNN pour les grilles ; GNN quand la relation entre entités est au cœur du problème.

4 Synergie LLM + GNN

GraphRAG, alignement texte–graphe, embeddings enrichis : texte et structure se complètent.

Message clé : sur ce scénario, la puissance reçue explique l'essentiel du SINR ; la topologie apporte un effet de second ordre, et ce résultat nuancé est lui-même valide.

Perspectives de recherche

1 Meilleur gNB

Prédiction d'arêtes (link prediction) comparée à la règle « meilleur SINR ».

2 Mobilité

UE mobiles, graphes dynamiques (GNN temporels), événements de congestion.

3 Architectures

Comparer GCN, GraphSAGE et GAT ; attention interprétable pour repérer les cellules interférentes.

4 Régression

Prédire le SINR ou le débit plutôt qu'une classe, avec impact sur débit et latence.

5 Données réalistes

ns-3 / 5G-LENA, modèles 3GPP [16], jeux de données opérateur.

6 LLM + GNN

GraphRAG sur les documents de réglementation et de planification radio, assistance à l'exploitation réseau.

Merci de votre attention

Questions et discussion

Fatima-Ezzahra Ghanam · Houda Bouya

Encadrant : Hassan EL GHAZI

INPT — Rabat · ANRT · 2026–2027